

Relatório Técnico de Conclusão de Curso de Pós-Graduação

Análise e Modelagem Preditiva da Evasão em Cursos de Graduação

Autores:

Erick Dias,

Werbert Wilson Severiano Chaves da Conceição,

Alexsander Prates,

Luciano Deschamps

RESUMO

O presente relatório técnico detalha a aplicação de técnicas de análise de dados e aprendizado de máquina para investigar e prever a evasão em cursos de graduação. O estudo utilizou um *dataset* de 5817 registros e 68 variáveis, seguindo a metodologia CRISP-DM, que incluiu o agrupamento de motivos de saída em categorias claras e a criação de variáveis de desempenho acadêmico (e.g., percentual de UCs aprovadas).

A análise descritiva revelou que as maiores causas de evasão se concentram em "Abandono/Desistência" (55.34%) e motivos "Institucionais (SENAI/SESI)" (18.00%). O modelo preditivo desenvolvido, uma Árvore de Decisão, alcançou uma Acurácia de 93.63% e um F1-Score de 0.9312, demonstrando alta capacidade de identificação de alunos evadidos (Recall de 98.70%).

A feature mais relevante para a predição de evasão foi o **"Tempo no curso em meses"** (importância de 0.4314), indicando que a decisão de evadir é tomada em estágios muito iniciais, com 98% das evasões ocorrendo nos primeiros 0 a 3 meses de curso. O relatório culmina com uma proposta de estratégia de intervenção e *deployment* do modelo, categorizando o risco de evasão em cinco níveis (Muito Baixo a Iminente) para ações proativas.

1. INTRODUÇÃO

1.1. Contextualização e Problema

A evasão em instituições de ensino superior representa um desafio significativo, impactando a sustentabilidade financeira das instituições e o desenvolvimento educacional e profissional dos alunos. Compreender os fatores subjacentes e ser capaz de prever quais alunos estão em maior risco é crucial para implementar estratégias de retenção eficazes.

1.2. Objetivo do Estudo

O objetivo primário deste trabalho é realizar uma análise aprofundada dos dados de matrícula e evasão de alunos de graduação para:

1. Quantificar a distribuição das situações de matrícula e os principais motivos de saída.
2. Desenvolver e avaliar um modelo de *Machine Learning* capaz de prever a probabilidade de evasão de um aluno.
3. Propor um plano de ação e *deployment* para utilização dos resultados na formulação de políticas de retenção proativas.

1.3. Estrutura do Relatório

O restante deste relatório está organizado da seguinte forma: a Seção 2 detalha a metodologia e o pré-processamento dos dados. A Seção 3 apresenta os resultados da análise descritiva e os principais achados. A Seção 4 descreve a construção e avaliação do modelo

preditivo. Finalmente, a Seção 5 apresenta as conclusões e as recomendações de intervenção e implementação.

2. METODOLOGIA E DADOS

2.1. Metodologia de Trabalho

O projeto seguiu o modelo **CRISP-DM (Cross-Industry Standard Process for Data Mining)**, abrangendo as fases de Entendimento do Negócio, Entendimento dos Dados, Preparação dos Dados, Modelagem, Avaliação e Sugestões de *Deployment*.

2.2. O Conjunto de Dados (Dataset)

O *dataset* original é composto por **5817 linhas** (registros de alunos) e **68 colunas** (variáveis). As variáveis incluíram dados demográficos, desempenho acadêmico (e.g., UCs aprovadas, cursando, reprovadas) e informações sobre a situação de matrícula e motivo de saída.

2.3. Pré-processamento e Classificação dos Motivos de Saída

Para facilitar a análise, a variável '**motivo_saida**' foi classificada em um número menor de categorias significativas por meio de um dicionário de classificação. As categorias resultantes são:

- Abandono/Desistência
- Acadêmico
- Financeiro
- Saúde
- Trabalho/Profissional
- Transferência
- Institucional (SENAI/SESI)
- Infraestrutura/Logística
- Indústria/Empresa.

A coluna '**motivo_saida**' também foi utilizada para imputar valores ausentes (NaN) na nova coluna '**motivo_categoria**' como "Abandono/Desistência", dado que valores nulos frequentemente representam evasão sem formalização¹⁷.

3. RESULTADOS E ANÁLISE

3.1. Distribuição da Situação de Matrícula

A distribuição da situação de matrícula reflete o universo da análise

Situação de Matrícula	Quantidade	Percentual (%)
Matriculado / Regular	1919	32.99%
Evadido / Eliminado	1864	32.05%
Evadido / Desistente	1335	22.95%
Trancado	543	9.33%
Transferido de Curso	156	2.68%
Total	5817	100.00%

O volume de alunos classificados como **"Evadido / Eliminado" (32.05%)** e **"Evadido / Desistente" (22.95%)** totaliza **55.00%** dos registros analisados, confirmando a alta taxa de evasão no contexto estudado.

3.2. Análise dos Motivos de Evasão

A classificação dos motivos de evasão revelou a concentração do problema em poucas categorias

Categoria do Motivo	Quantidade	Percentual (%)
Abandono/Desistência	3219	55.34%
Institucional (SENAI/SESI)	1047	18.00%
Transferência	474	8.15%
Acadêmico	432	7.43%
Financeiro	324	5.57%
Infraestrutura/Logística	163	2.80%
Trabalho/Profissional	86	1.48%
Saúde	70	1.20%
Indústria/Empresa	2	0.03%

Os motivos de **"Abandono/Desistência" (55.34%)** dominam a distribuição, sendo a categoria mais crítica para intervenção, seguida por motivos **"Institucionais (SENAI/SESI)" (18.00%)**.

Crucial: A análise cruzada entre a **Situação de Matrícula** e o **Motivo de Evasão** (Tabela de Contingência no anexo/apêndice) mostrou que alunos classificados como "Evadido / Eliminado" têm o motivo "Institucional (SENAI/SESI)" como a principal razão associada (50.48% dos eliminados).

3.3. Análise de Variáveis Acadêmicas e Demográficas

Variáveis como o percentual de Unidades Curriculares (UCs) aprovadas e o tempo no curso em meses foram essenciais para o modelo preditivo, conforme detalhado na Seção 4. As análises de características demográficas, como "Tipo de Deficiência", também mostraram alta concentração de evasão. Por exemplo, a categoria "Transtorno do Espectro Autista" (TEA) apresentou 100% de evasão (1 aluno).

3.4. O Fator Crítico: Tempo de Evasão

O achado mais crítico do estudo é a forte correlação da evasão com o tempo.

- **98% dos alunos evadidos o fazem nos primeiros 0 a 3 meses de curso.**
- A correlação do '**Tempo no curso em meses**' com a evasão é a mais forte encontrada (0.4314)

Este dado sublinha que as ações de intervenção devem ser **proativas e urgentes**, concentradas no período de adaptação do aluno, pois a evasão é decidida muito cedo, antes mesmo do desempenho acadêmico se consolidar como fator dominante.

4. MODELAGEM PREDITIVA

4.1. Seleção e Treinamento do Modelo

Para prever a evasão, foi selecionado um modelo de **Árvore de Decisão (*Decision Tree Classifier*)**. A Árvore de Decisão oferece interpretabilidade, permitindo que a lógica da predição seja compreendida e usada para orientar intervenções.

- **Hiperparâmetros:** O modelo foi ajustado com uma profundidade máxima (**max_depth**) de 10 e um número mínimo de amostras por *split* (**min_samples_split**) de 10.
 - **Variável Alvo (Target):** **evadido** (binária: 1 para evadido, 0 para não evadido).
-

4.2. Avaliação de Desempenho

O modelo de Árvore de Decisão apresentou excelente desempenho na classificação da evasão.

Métrica	Valor	Interpretação
Acurácia (Accuracy)	93.63%	Porcentagem de previsões corretas (evasão e não evasão).
F1-Score	0.9312	Média harmônica entre Precisão e Recall.
Recall (Evasão)	98.70%	Capacidade do modelo de identificar corretamente os alunos que irão evadir .
Precisão (Evasão)	88.46%	Dos alunos classificados como evadidos, a porcentagem que realmente evadiu.

O alto valor de **Recall (98.70%)** na classe "Evadido" é um resultado fundamental. Ele indica que o modelo supervisionado é extremamente eficaz em **detectar os casos positivos de evasão**, minimizando o risco de ignorar um aluno em situação de risco (Falsos Negativos), o que é ideal para um sistema de intervenção.

4.3. Importância das Variáveis

A análise da importância das variáveis confirmou a relevância de fatores temporais e acadêmicos.

Variável (Feature)	Importância (Score)
Tempo no curso em meses	0.4314
Percentual_UC_Aprovadas	0.1764
UC_Reprovada_ou_nao_cursada	0.1477
Qtd_UC_Reprovadas	0.0478
Qtd_UC_Aprovadas	0.0454

O "**Tempo no curso em meses**" é, de longe, o preditor mais importante (0.4314). Este dado, associado à constatação de que 98% das evasões ocorrem nos primeiros 3 meses, valida a necessidade de focar a intervenção no início do ciclo de vida do aluno.

5. CONCLUSÕES E RECOMENDAÇÕES

5.1. Sumário dos Achados

1. **Concentração da Evasão:** Mais da metade dos registros analisados são de alunos evadidos/eliminados (55.00%). Os motivos primários são "Abandono/Desistência" (55.34%) e questões "Institucionais" (18.00%).
2. **Fator Temporal Crítico:** A variável *Tempo no curso em meses* é a de maior importância para a predição. A evasão é um evento de **ocorrência precoce**, com 98% dos casos concentrados nos primeiros 3 meses.
3. **Modelo Preditivo Efetivo:** O modelo de Árvore de Decisão demonstrou alta capacidade de predição (Acurácia de 93.63%, Recall de 98.70%), sendo altamente confiável para **identificar alunos em risco de evasão**.

5.2. Estratégia de Deployment e Intervenção

O modelo preditivo deve ser integrado a um sistema de alerta para categorizar os alunos e disparar ações específicas. A predição da probabilidade de evasão deve definir o nível de risco e a urgência da intervenção.

Nível de Risco	Probabilidade de Evasão	Ação Recomendada
IMINENTE	> 70%	Ação urgente e imediata. Contato pessoal ou direcionamento a suporte específico.
ALTA	50% - 70%	Acompanhamento ativo. Monitoramento semanal e oferecimento de recursos (e.g., tutorias).
MÉDIA	30% - 50%	Alerta. Envio de comunicação informativa sobre recursos e apoio disponíveis.
BAIXA	10% - 30%	Estável/Monitoramento passivo.
MUITO BAIXA	< 10%	Seguro.

Recomendações de Monitoramento:

- **Novatos (0-3 meses):** Atualização SEMANAL do risco.
- **Alunos em Risco:** Atualização MENSAL.

KPIs Principais para Avaliação:

- Taxa de Retenção (Meta: 50%+).
- Tempo médio até evasão.
- Taxa de sucesso das intervenções.

5.3. Propostas de Ações Proativas

Dado que a evasão é precoce, as intervenções devem focar no período de 0-3 meses:

- Reforçar programas de ambientação e recepção.
- Oferecer suporte intensivo nas primeiras Unidades Curriculares.

motivo_categoria	Abandono/Desistência	Acadêmico	Financeiro	Institucional	Infraestrutura/Logística	Saúde	Trabalho/Profissional	Transferência	Indústria
Evadido / Eliminado	46.14%	0.64%	1.56%	50.48%	0.48%	0.11%	0.43%	0.00%	0.00%
Evadido / Desistente	27.72%	25.47%	15.51%	6.59%	10.79%	3.07%	5.39%	5.39%	0.15%
Evadido / Transf. Curso	18.75%	3.54%	1.46%	20.31%	2.08%	0.00%	0.00%	53.85%	0.00%

- Resolver **questões institucionais** e de **infraestrutura/logística** (que representam 18.00% e 2.80% dos motivos, respectivamente) nos primeiros dias de contato.

APÊNDICE: Tabelas de Suporte

A.1. Matriz de Confusão do Modelo Preditivo (Árvore de Decisão)

A matriz abaixo exhibe o desempenho do modelo na previsão de evasão (Classe 1) e não evasão (Classe 0).

Previsão (Predicted)	Não Evadido (0)	Evadido (1)
Real (Actual) - Não Evadido (0)	1007	157
Real (Actual) - Evadido (1)	40	3034

- Total de Evadidos corretamente identificados (True Positives): 3034.
- Total de Não Evadidos corretamente identificados (True Negatives): 1007.

A.2. Tabela Cruzada: Situação de Matrícula vs. Categoria do Motivo

- Esta tabela demonstra que a maioria dos "**Evadidos / Eliminados**" está associada a motivos **Institucionais (50.48%)** , enquanto "**Evadidos / Desistentes**" estão mais dispersos, com predominância em **Abandono (27.72%)** e motivos **Acadêmicos (25.47%)**.